

Θεωρητικό Υπόβαθρο

1. Mel-frequency Cepstral Coefficients (MFCCs)

Οι Mel-frequency Cepstral Coefficients είναι συντελεστές που εξάγονται από το mel-cepstrum και χρησιμοποιούνται σε συστήματα ανάλυσης φωνής. Ειδικότερα, το cepstrum είναι μία μη γραμμική μέθοδος ανάλυσης φωνής που επιλύει το πρόβλημα της αποσυνέλιξης. Το cepstrum βασίζεται στη σχέση

$$\hat{X}(z) = \ln[X(z)]$$

όπου $X(z)$ ο μετασχηματισμός Z του σήματος $x[n]$.

Το cepstrum διακρίνεται σε δύο κατηγορίες, το μιγαδικό-πλήρες και το απλό.

- Μιγαδικό cepstrum: $\hat{x}[n] = \frac{1}{2\pi} \int_{-\pi}^{\pi} \hat{X}(e^{j\omega}) e^{j\omega n} d\omega$
- Cepstrum (Bogert-Healy-Tukey): $\hat{x}[n] = \frac{1}{2\pi} \int_{-\pi}^{\pi} \log(|X(e^{j\omega})|) e^{j\omega n} d\omega$

Το πεδίο του cepstrum είναι το Quefrency και το $\hat{x}[n]$ είναι μία φθίνουσα ακολουθία.

Το mel-cepstrum είναι μία ειδική μορφή cepstrum που βασίζεται στην κλίμακα mel και στον short-time Fourier transform (STFT). Η κλίμακα mel ορίζεται ως

$$\text{mel}(f) = 1127 \ln \left(1 + \frac{f}{700} \right)$$

και μοντελοποιεί τις συχνότητες σύμφωνα με το πως οι άνθρωποι αντιλαμβάνονται τις διαφορές μεταξύ των συχνοτήτων. Προκειμένου να μετατρέψουμε ένα σήμα στην κλίμακα mel χρησιμοποιούμε την προσέγγιση των triangular filter banks, όπου κάθε φίλτρο είναι τριγωνικό με μέγιστη απόκριση τη μονάδα στην κεντρική του συχνότητα. Οι κεντρικές συχνότητες των φίλτρων είναι ομοιόμορφα κατανεμημένες στην κλίμακα mel.

Για την ανάλυση του συχνοτικού περιεχομένου των σημάτων φωνής χρησιμοποιείται το φασματογράφημα που υπολογίζεται με βάση το μέτρο του μετασχηματισμού STFT. Ο STFT ορίζεται ως

$$X(m, \omega_k) = \sum_{n=-\infty}^{\infty} x[n] w[n-m] e^{-j\omega_k n}$$

όπου $w[n]$ παράθυρο. Το παράθυρο, είναι ένα σήμα μικρής χρονικής διάρκειας που χρησιμοποιείται για την απομόνωση των frames από το αρχικό σήμα φωνής. Μάλιστα, λόγω της μικρής διάρκειάς τους, μπορούμε να τα θεωρήσουμε ως stationary διαδικασίες, παρότι τα σήματα φωνής είναι non stationary. Ειδικότερα, το κατάλληλο μέγεθος και είδος του παραθύρου, καθώς και η επιθυμητή επικάλυψη των πλαισίων (frame stride) εξαρτώνται από το εκάστοτε σήμα φωνής και το συχνοτικό του περιεχόμενο.

Στην πράξη, επιλέγουμε συνήθως smoothing παράθυρο, καθώς επιθυμούμε τα frames να μην έχουν υψηλές τιμές στα άκρα τους. Ένα τέτοιο παράθυρο, είναι και το Hamming window, που ορίζεται ως

$$w[n] = \begin{cases} 0.54 - 0.46 \cos\left(\frac{2\pi n}{L}\right), & 0 \leq n \leq L-1 \\ 0, & \text{otherwise} \end{cases}$$

όπου L το μέγεθος του παραθύρου.

Με βάση την έως τώρα ανάλυσή μας, γίνεται αντιληπτή η χρησιμότητα του mel-cepstrum σε συστήματα ανάλυσης φωνής, καθώς όχι μόνο οι συχνότητες βρίσκονται στην κλίμακα mel, αλλά και αρκεί μικρός αριθμός τελεστών για να αποθηκεύσουμε το συχνοτικό περιεχόμενο του αρχικού σήματος ανά τον χρόνο. Το mel-cepstrum ορίζεται ως

$$C_{mel}[n, m] = \frac{1}{R} \sum_{l=0}^{R-1} \log(E_{mel}(n, l)) \cos\left(\frac{2\pi}{R}(l + 0.5)m\right)$$

όπου R το πλήθος των mel φίλτρων.

Η $E_{mel}(n, l)$ είναι η ενέργεια του l mel-scale φίλτρου τη στιγμή n και υπολογίζεται από τη σχέση

$$E_{mel}(n, l) = \frac{1}{A_l} \sum_{k=L_l}^{U_l} |V_l(\omega_k)X(n, \omega_k)|^2$$

όπου U_l και L_l ο μέγιστος και ο μικρότερος δείκτης συχνότητας όπου το φίλτρο είναι μη μηδενικό και

$$A_l = \sum_{k=L_l}^{U_l} |V_l(\omega_k)|^2$$

Οι Mel-frequency Cepstral Coefficients αποτελούνται πρακτικά από cepstral coefficients ($c_t[i]$), για καθέναν από τους οποίους υπολογίζεται ένας delta cepstral coefficient ($d_t[i]$) και ένας double delta cepstral coefficient ($d_t^2[i]$) για κάθε frame t . Οι delta coefficients υπολογίζονται ως εξής

$$d_t[i] = \frac{\sum_{k=1}^K k (c_{t+k}[i] - c_{t-k}[i])}{2 \sum_{k=1}^K k^2}$$

$$d_t^2[i] = \frac{\sum_{k=1}^K k (\Delta c_{t+k}[i] - \Delta c_{t-k}[i])}{2 \sum_{k=1}^K k^2}$$

όπου K είναι η παράμετρος delta window.

Συνήθως, χρησιμοποιούνται 13 cepstral coefficients, 13 delta cepstral coefficients και 13 double delta cepstral coefficients, δηλαδή το MFCC αποτελείται κατά κανόνα από ένα διάνυσμα 39 χαρακτηριστικών. Σημειώνουμε ότι οι όροι $c_t[0]$, $d_t[0]$ και $d_t^2[0]$ αναφέρονται και ως energy coefficient, delta energy coefficient και double delta energy coefficient αντίστοιχα.

2. Γλωσσικά Μοντέλα (Language Models)

Ως γλωσσικό μοντέλο ορίζουμε ένα μοντέλο μηχανικής μάθησης, το οποίο εκτιμά την πιθανότητα εμφάνισης μελλοντικών λέξεων σε ένα κείμενο. Δηλαδή, πρόκειται για ένα μοντέλο που σύμφωνα με κάποιο κριτήριο υπολογίζει την πιθανότητα μία λέξη ή μία πρόταση να ακολουθεί του τωρινού κειμένου. Για τον σκοπό αυτό, απαιτείται συνήθως το σύνολο των λέξεων, το λεξικό, να είναι γνωστό.

Τα γλωσσικά μοντέλα είναι ένα βασικό εργαλείο με το οποίο δύναται να εκτιμηθεί η συνοχή και η συνέπεια ενός κειμένου, ώστε να εντοπιστούν και να διορθωθούν τυχόν λάθη. Σε ένα κείμενο, μπορεί να υπάρχουν διάφοροι τύποι σφαλμάτων διαφορετικής δυσκολίας εντοπισμού. Λάθη γραμματικής, ορθογραφικά και τυπογραφικά, εντοπίζονται με μία αναζήτηση στο λεξικό και μπορούν να διορθωθούν από σχετικά απλά γλωσσικά μοντέλα. Ωστόσο, ασάφειες και αντιφάσεις είναι πιο δύσκολο να αντιμετωπιστούν και συχνά απαιτούν προηγμένα γλωσσικά μοντέλα για να ανιχνευθούν και να διορθωθούν.

Συνεπώς, τα γλωσσικά μοντέλα μπορούν να περιορίσουν τα σφάλματα του κειμένου εισόδου και βρίσκουν εφαρμογή σε συστήματα επεξεργασίας φυσικής γλώσσας.

Υπάρχουν διάφορες κατηγορίες γλωσσικών μοντέλων, ορισμένα πιο απλά ως προς την υλοποίησή τους, όπως τα N-gram language models και άλλα περισσότερο περίπλοκα, όπως τα Large language models. Στην παρούσα εργασία όμως θα ασχοληθούμε με τα N-gram language models, τα οποία ορίζονται ως εξής.

Εστω $w_{i+1}, w_{i+2}, w_{i+3}, \dots, w_{i+N-1}$ οι τελευταίες $N - 1$ λέξεις του κειμένου. Τότε, η πιθανότητα η επόμενη λέξη του κειμένου να είναι η λέξη x , είναι ίση με:

$$\Pr[w_{i+N} = x] = \Pr[x \mid w_{i+1}w_{i+2}\dots w_{i+N-1}]$$

Τα N-gram language models είναι χρήσιμα σε περιπτώσεις όπου τα Large language models είναι δύσκολα υπολογιστικά, ωστόσο δεν χειρίζονται αποτελεσματικά τις συσχετίσεις μεταξύ λέξεων που εμφανίζουν απόσταση μεταξύ τους και δεν μοντελοποιούν ικανοποιητικά μη γνωστές ακολουθίες λέξεων.

Στην άσκηση, θα εργαστούμε με unigram ($N = 1$) και bigram ($N = 2$) μοντέλα.

Στην περίπτωση των unigram μοντέλων, οι πιθανότητες μπορούν να υπολογιστούν εύκολα ως $\Pr[w] = \frac{\text{count}(w)}{\text{total words}}$, ενώ για τα bigram μοντέλα $\Pr[w_i \mid w_{i-1}] = \frac{\Pr[w_{i-1}w_i]}{\Pr[w_{i-1}]} = \frac{\text{count}(w_{i-1}w_i)}{\text{count}(w_{i-1})}$. Βέβαια, για την αποφυγή underflow λόγω συνεχόμενων πολλαπλασιασμών με μικρούς αριθμούς, οι πιθανότητες υπολογίζονται και αποθηκεύονται σε λογαριθμική μορφή.

Ωστόσο, τα N-gram language models παρουσιάζουν καλές επιδόσεις μόνο εάν το test set είναι πανομοιότυπο με το train set. Ακόμα βέβαια και σε αυτές τις περιπτώσεις, δύναται να υπάρξει στο test set κάποια ακολουθία λέξεων που δεν παρουσιάζεται στο train set, με αποτέλεσμα το μοντέλο μας να έχει αναθέσει λανθασμένα μηδενική πιθανότητα στη συγκεκριμένη ακολουθία. Αυτός είναι και ο βασικός λόγος για τον οποίο τα N-gram language models δεν παρουσιάζουν σθεναρότητα και δεν είναι κατάλληλα για γενίκευση.

Προκειμένου να αποφύγουμε τις μηδενικές πιθανότητες, αναθέτουμε με βάση κάποιο κριτήριο (π.χ. add-one, interpolation, backoff) μικρή πιθανότητα στις ακολουθίες που δεν παρουσιάζονται στο training set.

Για την αξιολόγηση των γλωσσικών μοντέλων θα πρέπει να εκπαιδεύσουμε τα μοντέλα σε ένα train κείμενο να αξιολογήσουμε την επίδοσή τους σε ένα test κείμενο σύμφωνα με κάποια μετρική. Μία τέτοια μετρική είναι η perplexity (PP).

$$PP(w) = 2^{H(w)}, \quad H(w) = \frac{1}{M} \log_2 P(w)$$

όπου M το πλήθος των λέξεων. Μάλιστα, ισχύει ότι

$$PP(w) = 2^{H(w)} = P(w_1, w_2, \dots, w_M)^{-\frac{1}{M}}, \quad \text{καθώς } M \rightarrow \infty$$

Σύμφωνα με τη συγκεκριμένη μετρική, όταν οι προβλέψεις των λέξεων γίνονται πιο ακριβείς, δηλαδή όταν αυξάνονται οι δεσμευμένες πιθανότητες, η τιμή perplexity ελαττώνεται. Συνεπώς, ένα μοντέλο αξιολογείται ως καλύτερο από ένα άλλο αν εμφανίζει μικρότερη τιμή perplexity.

Στην περίπτωση του unigram μοντέλου $H(w) = -\frac{1}{M} \sum_{n=1}^M \log_2 P(w_n)$, ενώ στην περίπτωση του bigram μοντέλου $H(w) = -\frac{1}{M} \sum_{n=1}^M \log_2 P(w_n \mid w_{n-1})$.

Η perplexity είναι μία intrinsic evaluation, χρήσιμη για την εξαγωγή συμπερασμάτων για την απόδοση των γλωσσικών μοντέλων, ωστόσο δεν είναι ασφαλής για την εκτίμηση της επίδοσης τους σε πραγματικές εφαρμογές.